ESE5023 Assignment 02

Huang Xiaoqi 12632722

完成过程中参考了如下资料：

https://blog.csdn.net/tangxianyu/article/details/124210558

https://blog.csdn.net/jerrykorea/article/details/167268311

https://blog.csdn.net/weixin_42602241/article/details/154222469

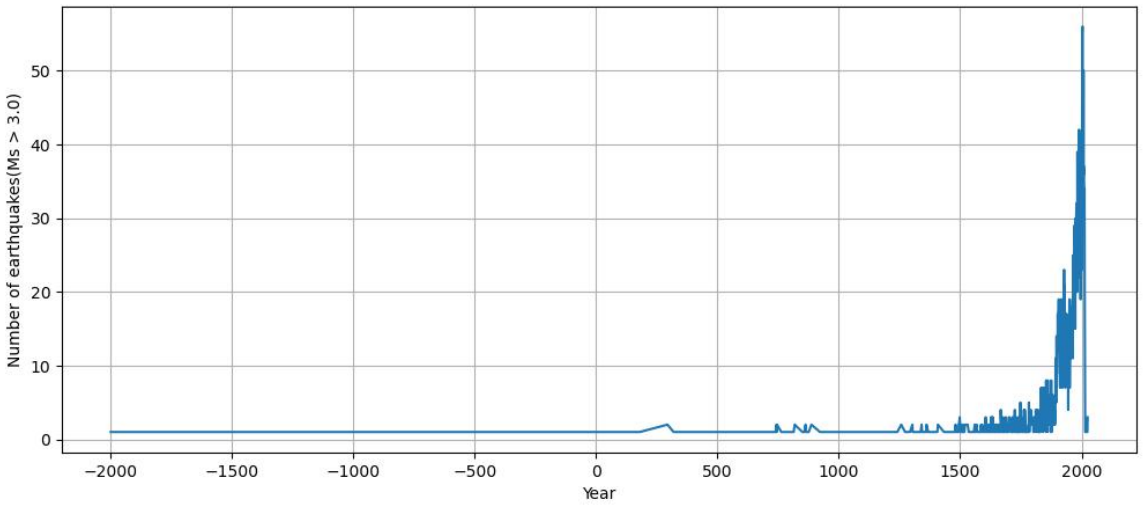
1. Significant earthquakes since 2150 B.C.

1.1

编程思路是先把统计对象从“单次地震”转换为“国家”。我使用 groupby("Country") 对数据分组，再对 Deaths 列调用 sum()，最后用 sort_values(ascending=False) 排序并用 head(20) 取前 20 名。这个写法利用 pandas 的分组聚合完成整列计算，避免逐行循环。

1.2

编程时先用布尔索引 Sig_Eqs[Sig_Eqs["Ms"] > 3.0] 筛选震级条件，再按 Year 分组并用 size() 统计每年的记录条数，最后以年份为横轴绘制折线图。我观察到的趋势是：记录数量在近现代明显增加，尤其是 20 世纪以后；但这不能直接说明真实地震发生频率增加。我推测是因为早期记录不完整，而现代地震台网和数据库提高了检出率。



1.3

CountEq_LargestEq 的核心是把一次查询封装成可复用函数。函数先按 Country 做布尔筛选，用 len(country_data) 得到记录数；再用 notna() 判断 Mag 是否存在有效值。如果没有有效震级，就返回 No data；否则用 idxmax() 定位最大震级所在行，并从该行读取 Year、Mo、Dy

和 Location Name。主程序遍历 Country 的非空唯一值，把函数返回的元组写入列表，再转换为 DataFrame 并按 Earthquake_Count 降序排列。这样将“筛选—异常处理—定位最大值—整理输出”固定为同一套流程。

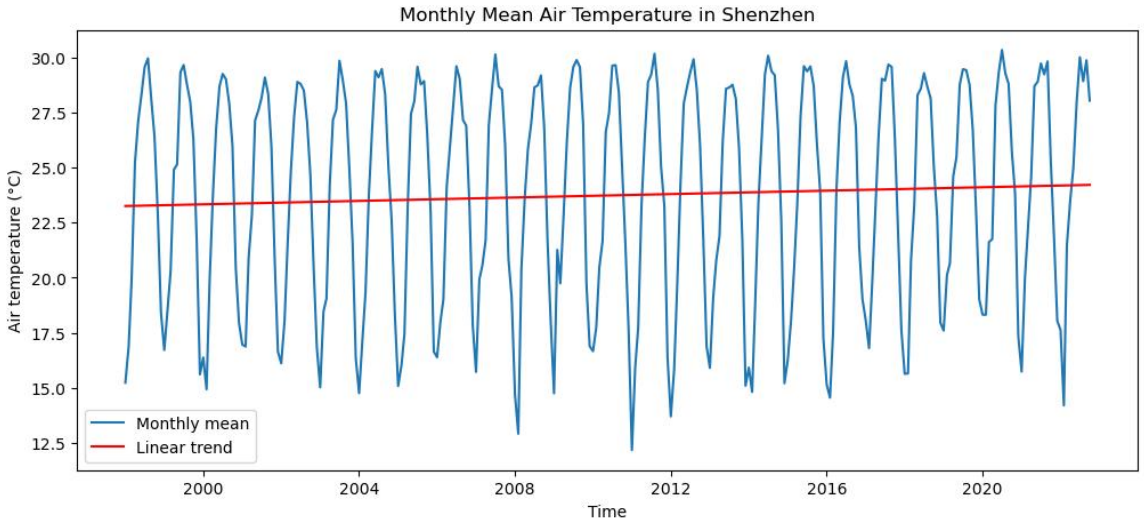
这一题的主要编程收获是处理边界情况。部分国家没有有效 Mag，部分历史记录缺少月份或日期。如果不先判断缺失值，idxmax() 或整数转换可能报错。因此我先检查有效值数量，并在日期缺失时保留 NA。

2. Air temperature in Shenzhen 1998 to 2022

2.1

数据筛选过程如下。首先用 str.split(",", expand=True) 把 TMP 拆成温度编码和质量码；温度编码用 to_numeric(errors="coerce") 转为数值，再除以 10 得到摄氏度，DATE 用 to_datetime() 转为时间。随后同时满足两个条件才保留记录：温度编码不等于缺测标记 +9999，且质量码属于 0、1、4、5、9。最后把 time 设为索引，使用 resample("MS").mean() 计算月平均温度。这一筛选避免把缺测编码当作真实温度，也只保留题目要求的质量记录。

为了判断趋势，我把距离首月的时间换算成年，用 stats.linregress() 对月平均温度做线性回归，并把拟合直线叠加到原时间序列上。回归斜率为 0.038736 ℃/年，说明拟合结果呈轻微上升倾向，相当于每十年约升高 0.39 ℃。但是，回归的 p 值为 0.339，大于 0.05，表明该上升趋势在统计上不显著。因此，1998—2022 年的月平均气温表现出轻微升温倾向，但是不能认为其存在显著的线性升温趋势。



这一部分让我认识到，画出趋势线只是程序输出的一部分，还必须用统计量解释输出。代码同时报告 slope 和 pvalue，避免只凭图形下结论。若进一步分析，我会先去除强烈的季节循环，例如计算月距平或年平均温度，再检查缺测、自相关和异常值对回归结果的影响。

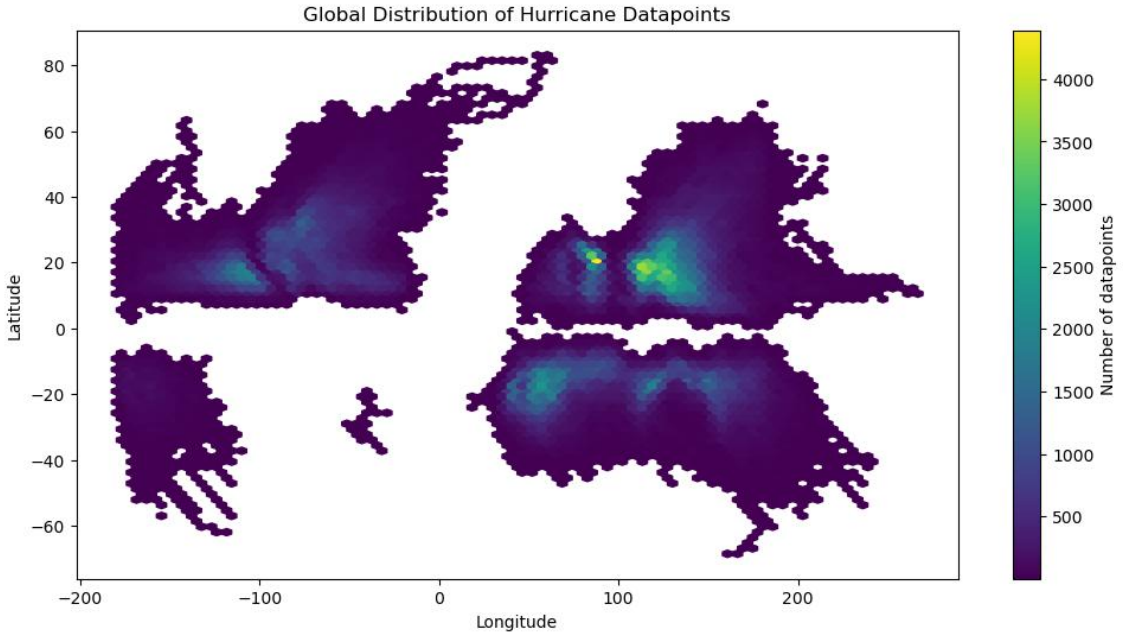
3. Global collection of hurricanes

3.1 - 3.3

读取 IBTrACS 时，我在 read_csv() 中用 usecols=range(17) 限定所需列，用 skiprows=[1] 跳过单位行，用 parse_dates 把 ISO_TIME 直接解析为时间，并设置缺失值。随后用 to_numeric(errors="coerce") 统一 WMO_WIND、LAT 和 LON 的类型。对于 3.1 和 3.2，我按 SID 分组，用 agg(NAME=("NAME", "first"), WMO_WIND=("WMO_WIND", "max")) 为每个风暴保留名称和最大风速，再排序一次，同时得到前 10 个名称和前 20 个最大风速。这样避免把同一风暴的多个轨迹点重复当成多个风暴。3.3 直接用 groupby("BASIN").size() 统计各海盆的行数并降序排列。

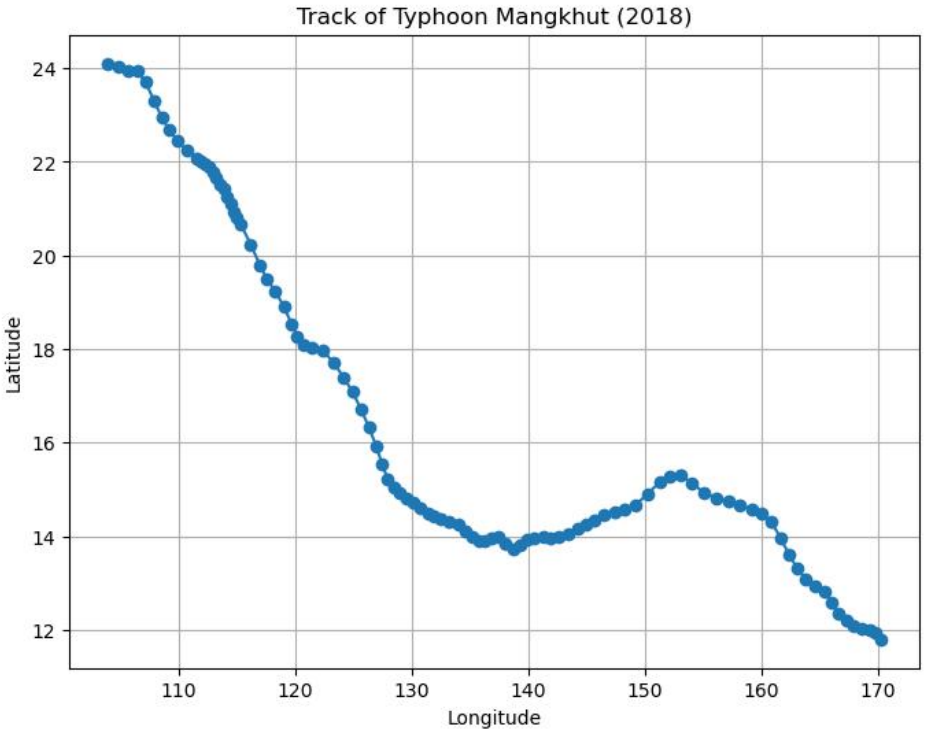
3.4

3.4 我使用 plt.hexbin(df["LON"], df["LAT"], gridsize=80, mincnt=1) 对经纬度点做二维分箱。与直接绘制几十万个散点相比，hexbin 会在每个六边形网格内累计点数，既减少遮挡，又能用颜色显示密度。学到了一种新的数据统计与制图展示的方法。



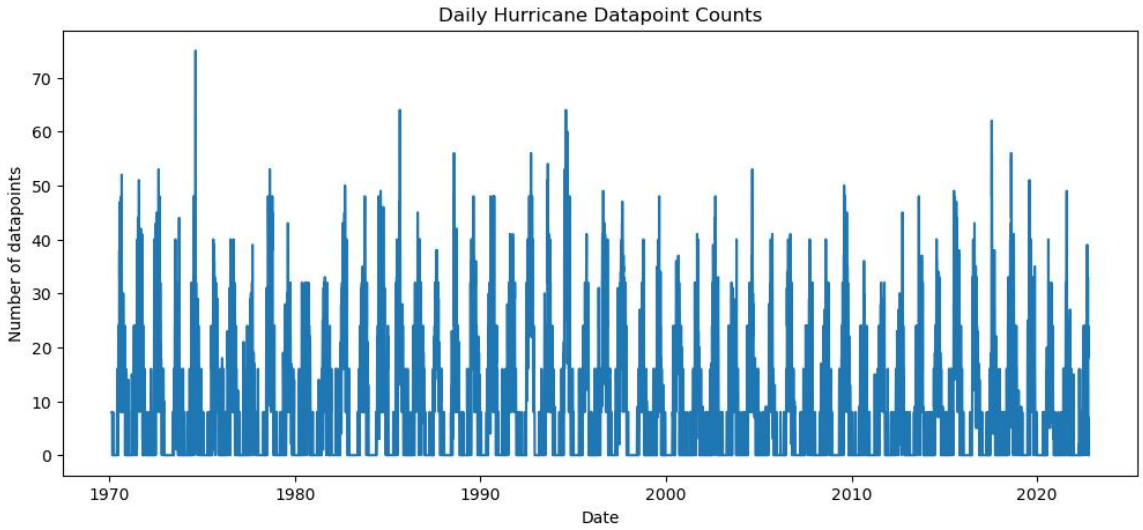
3.5

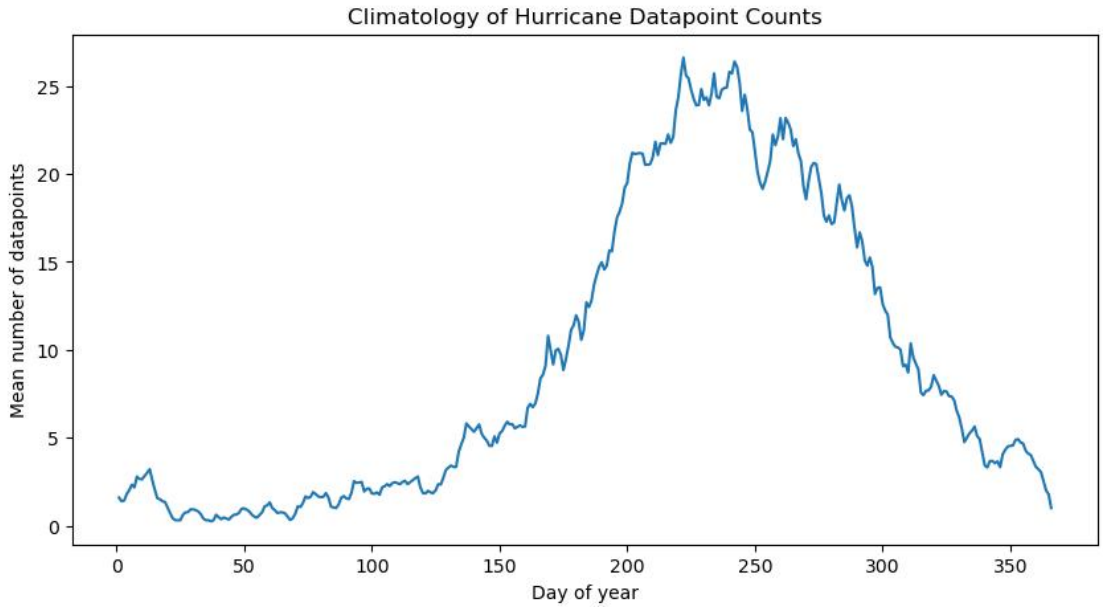
3.5 用两个布尔条件同时筛选 SEASON == 2018 和 NAME == "MANGKHUT"，再用 sort_values("ISO_TIME") 按时间排序。这道题排序非常重要！！如果直接按原始行顺序连接，轨迹会出现时间跳跃。结果显示 Mangkhut 从西北太平洋向西北方向移动，经过菲律宾附近后进入南海。



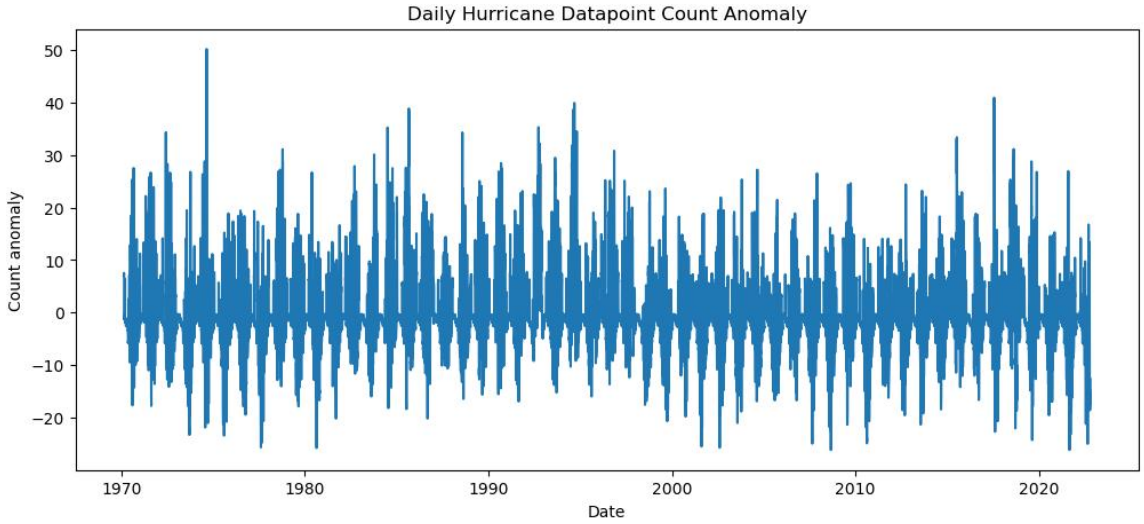
3.6 - 3.10

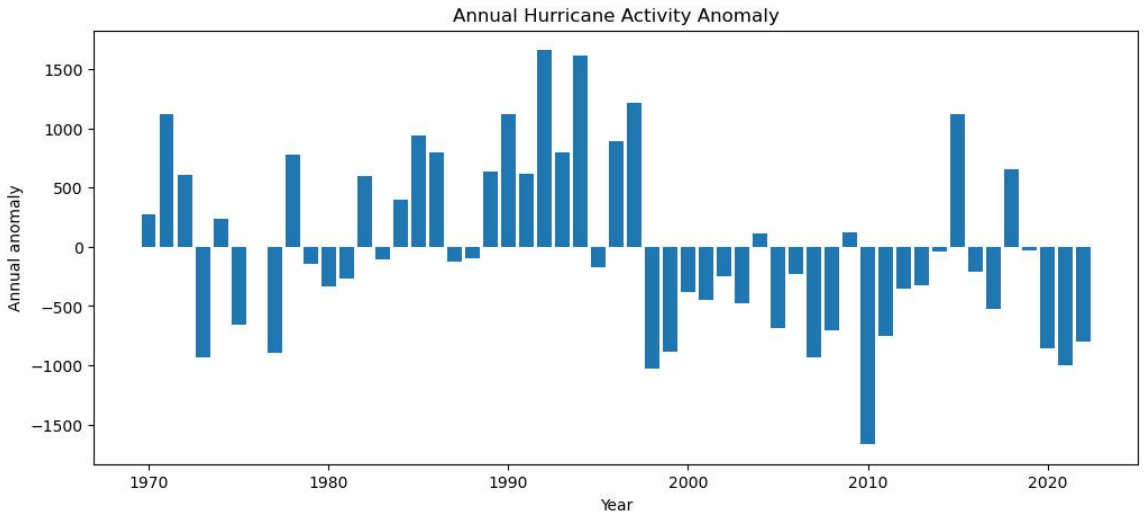
3.6 先用年份条件和 isin(["WP", "EP"]) 得到 1970 年以来两个海盆的副本。3.7 把 ISO_TIME 设为索引，用 resample("D").size() 得到每日数据点数。3.8 从索引提取 dayofyear，再按 day_of_year 分组求平均，得到 1—366 日的气候平均。图中暖季计数明显较高，日序约 220—250 附近达到峰值。





3.9 用 map(climatology) 为每一天匹配相同日序的气候平均，再计算 anomaly = count - climatology。3.10 对异常序列调用 resample("YS").sum() 得到年异常，并排序寻找最突出年份。正异常最高的五年是 1992、1994、1997、1990 和 2015；负异常最低的五年是 2010、1998、2021、2007 和 1973。





4. Explore a data set

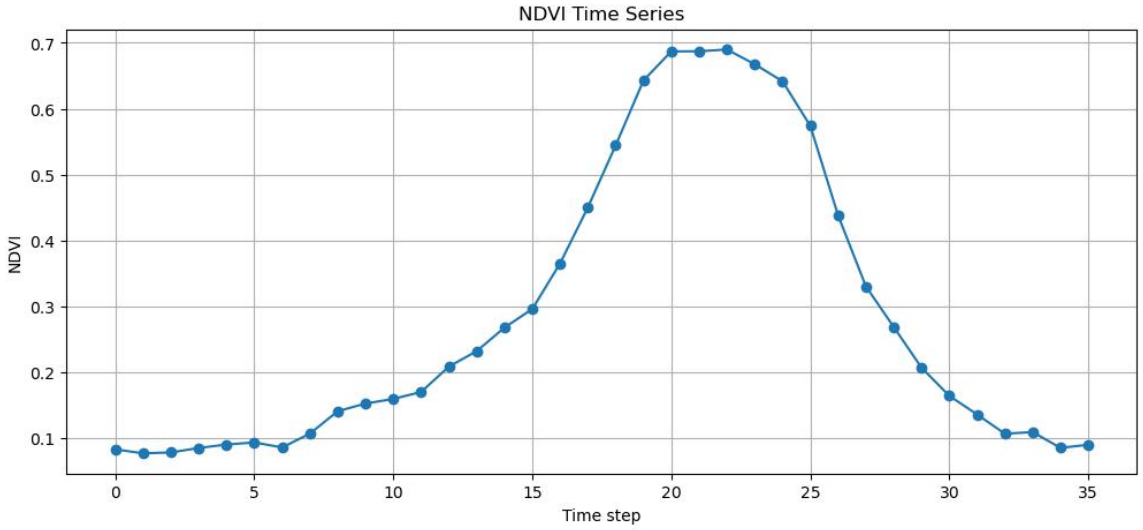
该数据来自我之前开展的作物 mapping 工作。每一行代表一个样本，label 为作物类别，red 和 NIR 分别记录红光与近红外波段的反射率。数据覆盖一个完整年份，以 10 天为一个时间步，共包含 36 个时间步，因此 red_00 和 NIR_00 表示年初第一个时间段，red_35 和 NIR_35 表示年末最后一个时间段。

4.1

这道题我 先调用 dropna() 和 drop_duplicates() 删除缺失行与重复行。为了不把类别标签当作遥感特征，我用 data.columns.drop("label") 得到 feature_columns；随后分别判断所有特征是否 >= 0 和 <= 255，进行数据清洗。

4.2

4.2 使用 for i in range(36) 生成 red_00—red_35 和 NIR_00—NIR_35 的列名，但每个时间步内部仍用 pandas 向量运算一次计算全部样本的 NDVI，即 (NIR - red) / (NIR + red)。把 36 列结果组成新的 DataFrame 后，用 mean() 沿样本方向求平均时间序列。结果显示，平均 NDVI 从年初约 0.08 逐渐上升，在第 20—22 个时间步达到约 0.69，之后下降至年末约 0.09，呈现明显的单峰年内变化。



4.3

为了从整体上检查 NDVI 数据的分布，我先使用 to_numpy().flatten() 将包含全部样本和 36 个时间步的 NDVI DataFrame 展平成一维数组，使不同时间步的数据可以统一参与统计。随后分别调用 mean()、median()、std()、min() 和 max()，得到均值、中位数、标准差、最小值和最大值。相比逐个时间步循环统计，这种写法更简洁，也便于快速检查整个数据集的取值范围和离散程度。

全部 NDVI 的均值为 0.283659，中位数为 0.190476。均值高于中位数，说明数据中一部分较高的 NDVI 值将整体均值向上拉动，这与作物在旺盛生长期具有较高 NDVI 的特点相符。标准差为 0.263787，表明不同样本和不同时间步之间存在较明显的差异，这些差异既来自不同作物类别，也来自同一作物在一年中不同生长阶段的变化。最小值为 -0.647059，是因为部分样本为非植被地物；最大值为 0.885057，说明部分样本在某些时间步具有较高的植被覆盖度和较旺盛的生长状态。

5. Reflection

这次作业让我更清楚地理解了 pandas 中“数据层级”和“统计对象”的关系。地震题按 Country 聚合，热带气旋题既有轨迹点层级，也有 SID 风暴层级。如果没有先判断一行代表什

么，就可能把数据点数量误写成风暴数量。groupby、agg、size 和 sort_values 的组合，使我能把不同层级的计算写成清晰的数据处理链。

也明白了数据清洗是编程的非常重要的一部分。TMP 需要先拆分字段、转换类型并按质量码筛选；IBTrACS 的数值列要用 errors="coerce" 处理非数值内容；自选数据还要把 label 从特征范围检查中排除。把这些规则明确写进代码后，后续统计才具有一致输入。

时间序列部分的收获主要来自日期索引和 resample。深圳温度从小时记录转换为月平均，飓风数据从不规则轨迹点转换为日计数和年异常。dayofyear、groupby 和 map 又把季节循环与异常联系起来。相比直接在循环中手工累计，pandas 的时间索引方法更简洁，也更容易检查时间范围和频率。